

规则引擎黑盒验证报告

注:本文记录验证的方法、数据与结果，并给出问题定位与阅读指引，不包含任务分配或改动方案。

1. 验证对象

组成	路径
规则入口	backend-rust/src/rules/engine.rs （ candidate_categories / normalize_finding ）
YAML 规则	backend-rust/src/rules/data/conditions.yaml
类别目录	backend-rust/src/rules/data/catalog.yaml
类别定义	backend-rust/src/rules/catalog.rs （15 个风险类别）
命令行验证工具	backend-rust/src/bin/eval_rule.rs （本次验证新增）
白盒测试	backend-rust/tests/rule_engine_verify.rs （本次验证新增）

2. 验证方法

2.1 白盒验证（对照基线）

针对规则引擎已知行为构造的测试用例，用于确认引擎“能否正确执行其自身声明的规则”。

测试文件 backend-rust/tests/rule_engine_verify.rs ，共 4 个用例：

用例	内容
candidate_categories_covers_all_15_risk_types	15 个风险类别各有对应命中文本
benign_clauses_are_not_flagged	空白 / 正常经营描述 / 合规条款不误报
yaml_only_cases_fill_hardcoded_blind_spots	仅 YAML 规则可命中的补位用例 （硬编码无法命中）
critical_red_line_judgement	8 个应判定 Critical + 7 个不应判定 Critical

结果：

test result: ok. 4 passed; 0 failed

2.2 黑盒验证（本报告主体）

- 语料： backend-rust/tests/fixtures/golden_sections.json
 - 对应源文件： backend-rust/tests/file/智慧教室环境改造工程.pdf （东莞理工学院松山湖校区智慧教室环境改造工程（二期）竞争性磋商文件）
 - 规则引擎定制过程中未针对该语料逐条调优。
- 规模：302 条带正文的条款（ sections 递归叶子节点）。
- 工具： cargo run --bin eval_rule -- "<条款文本>" 。
- 批量方式：遍历 302 条，逐条调用 eval_rule.exe ，命中判定以输出 → 命中 为准（→ 未命中 不计入命中）。
- 人工复核口径：对每条命中条款，依据《中华人民共和国政府采购法》《中华人民共和国招标投标法》及实施条例等，判断是否构成实质性排斥 / 限制竞争风险。

3. 黑盒结果（全量 302 条）

- 命中：32 条（10.6%）
- 未命中：270 条
- 命中类别分布：

类别	命中次数
SHORT_DEADLINE	20
UNRELATED_CERT	5
CONFLICTING_DATES	2
VAGUE_ACCEPTANCE	2
UNILATERAL_CHANGE	1
EXCESSIVE_DEPOSIT	1
SCALE_THRESHOLD	1
OEM_AUTHORIZATION	1
BRAND_LOCK	1

- 人工逐条复核：32 条命中中，认定为实质性违规的条款 **0 条**；认定为误报的条款 **32 条**。
- Precision = 0 / 32 = **0%**。
- Recall 说明：未命中侧（270 条）未做逐条 Recall 审计；该语料为规范备案文本，未发现明显应命中而漏报的排斥性条款。因缺少独立 ground truth 标注，Recall 无法量化。

4. 误报明细（32 条）

4.1 SHORT_DEADLINE（20 条）

条款编号	条款关键片段	触发词
14	自响应文件发出至截止之日止，不得少于10个日历日	少于
15	公告期限自发布之日起不得少于3个工作日	少于
173	评审专家不得少于成员总数的三分之二	少于
225	提交最后报价的供应商不得少于3家	少于
65	当家数不足时项目将不得开启	不足
98	不足5日的，代理机构顺延截止时间	不足
197	供应商不足3家的	不足
366	违约金不足以弥补所造成的直接经济损失	不足
215	投标有效期不足的...无效	不足
107	带★条款未响应或不满足，按无效处理	不满 ("不满足")
214	审查是否不满足各审查表要求	不满 ("不满足")
479	负偏离或不满足则响应无效	不满 ("不满足")
483	同 479（重复条款）	不满 ("不满足")
159	答复期满后15个工作日内提起投诉	工作日 正则
349	乙方应在3日内补齐质量保证金	3日内 正则
363	乙方应在接到通知之日起3日内到场维修	3日内 正则
53	工程质保期限为2年...质保期自实际竣工日起算	日期 碎片
284	工程质量与施工安全教育培训、定期考核	日期 碎片

条款编号	条款关键片段	触发词
226	评审分值构成...技术响应...商务/技术/报价分	截止/日
368	违约金第3天起算...履约保证金扣除	第3天

4.2 UNRELATED_CERT（5 条）

条款编号	条款关键片段	触发词
12	为项目提供设计、 监理等服务的供应商不得再参与本项目投标	资质（法定排除条款）
67	无法使用CA证书在云平台解密时...启用非加密响应文件	CA证书
93	提供翻译资质机构的中文译本...翻译人员资格证书	证书/资质
114	携带并使用制作响应文件的同一数字证书参加开启解密	数字证书
229	技术负责人具有工程师职称证书，须提供复印件	职称证书

4.3 其余类别（7 条）

条款编号	命中类别	条款关键片段
64	CONFLICTING_DATES	本表与磋商文件对应章节内容若不一致，以本表为准
453	CONFLICTING_DATES	地址：___ 电话：___ 传真：___（空白表单模板）
304	VAGUE_ACCEPTANCE	制定并落实安全生产规章制度，严格执行施工技术规范
369	VAGUE_ACCEPTANCE	安全文明施工责任...措施费总额1%~50%违约金
305	UNILATERAL_CHANGE	甲方有权责令乙方暂停施工和单方面终止合同
456	BRAND_LOCK	投标客户端软件...在线生成分项报价表
466	SCALE_THRESHOLD	属于（中型企业、小型企业、微型企业）...声明

5. 问题所在（问题诊断）

5.1 现象

在一份规范、已备案的真实磋商文件上，引擎命中 32 条，复核后 0 条属实。命中的 32 条全部是被误判的正常条款，其中 62%（20 条）集中在 `SHORT_DEADLINE` 一类。

5.2 直接原因（规则层病灶）

属于“某几条规则写得太宽”的表层问题，可从规则文件直接定位：

- `TIME_SHORT_DEADLINE`（`conditions.yaml`）使用 `check: any_match`，且 `patterns` 含关键词 `["不足", "少于", "仅有", "只有", "不满"]` 与正则 `'[1-9]\s*日.{0,6}(内|以内|之后|前)'`，任一模式单独命中即触发；
- `engine.rs` 硬编码中 `UNRELATED_CERT` 分支用 `["认证", "证书", "荣誉", ...]` 与 `["资格", "无效", "废标", "必须", "须提供", ...]` 共现判定；
- `SAFE_ACCEPTANCE_ABSENCE`（`conditions.yaml`）以 `match_mode: absence` “未提及『安全生产许可证』即命中”。

以上是“病灶”，但不是问题的根本。

5.3 根本原因（方法论层缺失）

这套引擎的根本问题在于：它把“自然语言是否违规”这道语义判断题，交给了“字符串子串匹配”这种无语义的机械操作。具体表现为三种缺失：

缺失一·规则作用在“原始字符串”上，而非“语义要素”上

规则匹配的对象是字符序列（`contains("少于")`），而不是语义判断（“投标准备期限 < 法定最短期限”）。结果是同形异义被混为一谈：“不得少于 10 个日历日”（表达 $\geq$ ）与“少于 10 个日历日”（表达 $<$ ）字面都含“少于”，语义相反，却被归入同一规则。行业对照参见第 6 节指引 A：先做要素抽取，规则作用在结构化要素上。

缺失二·否定与比较语义未建模

“不得少于 / 不予接受 / 不因...顺延”这类否定结构没有被识别，因此“不得少于”被读成“少于”。这属于自然语言处理中的否定检测（negation detection）与语义极性判断，是当前实现完全缺失的能力。

缺失三·无证据定位与上下文约束，导致“召回”被当成“判定”

命中结果只返回类别码，不返回“由哪几个字、在什么上下文触发”。叠加 `any_match` 使单一关键词即可拍板“违规”，等于把“疑点召回”直接当成了“最终判定”。而规则命中在行业做法中只应是“召回 + 证据 span”，最终判定由精判环节承担（指引 B）。

5.4 问题的一句话定义

本引擎的核心问题不是“某条规则写错”，而是**架构上缺少“语义要素抽取 + 否定识别”这一层，并把无语义的字符串匹配直接当成了最终判定**。白盒测试无法暴露此问题（白盒是按规则出题），只有黑盒真实语料才能暴露。

6. 指引（阅读方向）

以下指引只说明“要理解这个问题、或要了解对应做法，应查阅什么”，不构成改动力案。

- **指引 A —— 为什么字符串匹配必然误报，及替代做法：**阅读“条款分类 + 要素抽取”类方案。
→ [CN115269874A — 基于自然语言理解的智能合同审查（条款分类模型 + 要素抽取模型）](#)、[Meritdata：为什么 chunk 级 RAG 无法支撑确定性的条款级审查](#)。
- **指引 B —— “规则 / 检索只召回、LLM 精判、人评估”的分层分工：**
→ [Agent + 规则引擎 + 大模型：合同智能审查的三层校验架构](#)、[腾讯电子签 AI 合同智审（混合技术架构）](#)、[基于通义千问的全 AI 合同审查](#)。
- **指引 C —— 专业化规则引擎（不再用 `contains`，而是声明式规则 + 结构化事实）：**
→ [Drools + 混元大模型：企业级智能决策的「规则 + 底线」双引擎](#)、[CN113722421B — 基于 Drools 的合同审计系统](#)。
- **指引 D —— 把自然语言转成可确定性校验的逻辑表示（否定/比较如何在逻辑层被正确表达）：**
→ [Large Language Models for translating contract-related texts to logical predicates（ESWA）](#)、[Towards Trustworthy Legal AI through LLM Agents and Formal Reasoning](#)、[RuleBricks: Bridging AI Contract Analysis with Deterministic Execution](#)。
- **指引 E —— 规则 + 检索 + 图的多 Agent 混合推理：**
→ [A Hybrid RAG and Rule-Based Reasoning Framework for Technical Document Analysis（Frontiers）](#)、[LegalGraphRAG: Multi-Agent Graph Retrieval-Augmented Generation](#)。

7. 结论（事实陈述）

1. 规则引擎能够正确执行其声明的规则（白盒验证 4 passed）。
2. 规则引擎在独立真实语料（302 条）上，命中 32 条，逐条复核后 0 条构成实质性违规，Precision = 0%。
3. 表格层面原因是若干规则（`TIME_SHORT_DEADLINE` 的 `any_match`、硬编码关键词共现、`absence` 模式）过宽。

4. 根本原因是引擎以原始字符串为匹配对象、缺少语义要素抽取与否定识别，并将“召回”直接当作“判定”。
5. 该缺陷只能由独立真实语料的黑盒验证暴露，自测（白盒）不能暴露。

8. 参考与借鉴（完整链接清单）

8.1 实践与架构

- [腾讯电子签 AI 合同智审：基于混合技术架构的企业合同风险智能审查解决方案](#)
- [Agent + 规则引擎 + 大模型：合同智能审查的三层校验架构设计](#)
- [基于通义千问：全 AI 自动驱动合同审查系统的技术解构与实践](#)
- [Drools + 混元大模型：企业级智能决策的「规则 + 底线」双引擎](#)
- [RAG 技术赋能智能合同审查（百度）](#)

8.2 专利

- [CN113722421B — 基于 Drools 规则引擎的合同审计系统](#)
- [CN115269874A — 基于自然语言理解的智能合同审查（条款分类 + 要素抽取）](#)

8.3 论文

- [A Hybrid RAG and Rule-Based Reasoning Framework for Technical Document Analysis \(Frontiers in Artificial Intelligence\)](#)
- [Large Language Models for translating contract-related texts to logical predicates \(Expert Systems with Applications\)](#)
- [Towards Trustworthy Legal AI through LLM Agents and Formal Reasoning](#)
- [LegalGraphRAG: Multi-Agent Graph Retrieval-Augmented Generation for Reliable Legal Reasoning](#)

8.4 技术博客

- [RuleBricks: Bridging AI Contract Analysis with Deterministic Execution](#)
- [Why ChatGPT Isn't Enough: Chunk-Based Legal RAG Fails for Deterministic Clause-Level Contract Intelligence \(Meritdata\)](#)

9. 规则引擎应达到的程度

9.1 职责边界

- 规则引擎**适用**的判断：确定性、可枚举、结构化后可逻辑表达的条件（例：“投标准备期天数 < 20”“保证金比例 > 2%”）。
- 规则引擎**不适用**的判断：依赖语境、价值权衡、开放式语义（例：“是否构成以不合理条件限制潜在供应商”），此类归精判环节。
- 规则命中的合理角色：**候选线索 + 证据定位**；最终判定不归属规则引擎。

9.2 能力程度分级

L1 · 不可用（本次验证所处程度）

项目	状态
匹配对象	原始字符串
否定 / 比较语义	无
证据定位	无（仅返回类别码）
命中语义	命中即结论

表征：白盒可全绿，黑盒 Precision = 0%（见第 3 节）。

L2 · 可用（合格线）

项目	状态
匹配对象	结构化语义要素（先抽取要素，再对要素判规则）
否定 / 比较语义	具备（“不得少于”识别为 ≥ 并排除）
证据定位	命中附带触发原文片段
命中语义	候选线索，由精判环节决定

表征：规则命中的误报可控；Recall 由精判环节兜底。

L3 · 可靠（进阶线）

项目	状态
推理方式	自然语言条款转逻辑谓词后做确定性推理
评估体系	具备独立 golden 集，可回归 P / R / F1
可解释性	每条结论可回溯到“证据原文 → 规则 → 逻辑链”

表征：准确率可量化、可复现、可审计。

9.3 判断“是否达到”的执行标准

以下四项可作为衡量“距离可用还有多远”的对照项，括号内为本次验证的现状：

- 1. 存在一份独立于规则编写过程的测试集，可在其上报告 Precision / Recall / F1（**当前：无，Recall 无法量化**）。
- 2. 每条命中可回溯到触发它的原文证据（**当前：仅返回类别码**）。
- 3. 否定结构（不得少于 / 不予接受 / 不因...顺延 等）不再产生语义反转误报（**当前：产生，见第 4.1 节**）。
- 4. 规则命中不再直接等同于最终判定，而是作为进入精判环节的候选线索（**当前：命中即结论**）。